

למידת מכונה

מטלת סיכום – חלק 2

בניית מודל חיזוי דירוג סרטים

1. סקירה כללית

זהו החלק השני (מתוך שלושה) במטלות הסיום. הוא מבוצע גם עבור קורס למידת מכונה, ויוגש דרך המודל של הקורס למידת מכונה. בחלק 1 בנייתם סט נתונים מקיף של סרטים מ-IMDb. בחלק זה תבנו מודל שחזזה את הדירוג הממוצע (averageRating) של סרט בטרם יציאתו לאקרנים – תוך שימוש בשדות הידועים טרם הרצת הסרט.

המטלה תבוצע ביחידים או זוגות בלבד!

2. נתוני הקלט ומשתנה המטרה

2.1 נתוני הקלט

נקודת ההתחלה היא קובץ dataset.csv שניתן להוריד ב**קישור**, בהתאם למבנה הדאטה אותו יצרתם בחלק 1. יש לקרוא אותו ל-DataFrame ולעבוד עליו. בנוסף, מותר (ומומלץ) להעשיר את הדאטה בנתונים נוספים שנאספו בחלק 1 בתור רשות, ובנתונים חיצוניים שתוסיפו במסגרת feature engineering

2.2 משתנה המטרה (Target)

משתנה המטרה הוא **averageRating** – הדירוג הממוצע של הסרט (1.0–10.0).

2.3 מניעת Data Leakage – חובה

אסור להשתמש בשדות שאינם קיימים בזמן יציאת הסרט לאקרנים. במיוחד:

- **averageRating** – משתנה המטרה, אסור כפיצ'ר
- **numVotes** – מספר המדרגים, מצטבר אחרי היציאה
- **BoxOffice** – הכנסות, מצטברות אחרי היציאה

כל שימוש באחד השדות האלה כפיצ'ר ייחשב כ-leakage ויגרור הורדה משמעותית בציון. סעיף ייעודי בדוח חייב להסביר כיצד וידאתם את מניעת ה-leakage (כולל במסגרת ה-pipeline של ה-cross validation).

3. דרישות טכניות

3.1 פונקציית prepare_data

יש להגדיר פונקציה בשם **prepare_data(df)** שמקבלת DataFrame במבנה הגולמי של הדאטה מחלק 1, ומחזירה DataFrame מעובד הכולל רק את השדות הרלוונטיים למודל (לרבות פיצ'רים שיצרתם לבד). הפונקציה חייבת להיות דטרמיניסטית ולרוץ ללא שגיאה גם על שורה בודדת וגם על סט של מאות סרטים. הפונקציה תופעל במעמד הבדיקה על **test set** חיצוני שלא ראיתם. אם הקוד לא רץ – תאבדו את כל הנקודות על סעיף התחרות.

3.2 מודלים

יש לבנות שני מודלים לפחות:

- מודל **Elastic Net** (חובה) – עם tuning של α ו- $l1_ratio$ ב-cross validation
 - מודל שני לבחירתכם: Decision tree, Random Forest. חובה לנמק את בחירת המודל בדוח.
- יש להשתמש ב-Pipeline כך שכל עיבוד מקדים (imputation, scaling, encoding) קורה בתוך ה-cross validation – על fold האימון בלבד. leakage של scaling/encoding הוא שגיאה נפוצה ולא מקובלת.

3.3 הערכה

יש לבצע **10-fold cross validation** ולדווח על מדדי הביצוע: $RMSE$, MAE , R^2 . יש לדווח ממוצע וסטיית תקן לכל מדד על פני ה-folds.

4. Feature Engineering

חובה להנדס לפחות 5 פיצ'רים חדשים מעבר לעמודות הגולמיות של חלק 1. בתוך ה-5 האלה חייבים להיכלל לפחות פיצ'ר אחד נומרי מורכב (ratio, interaction, binning) של פיצ'ר קיים וכו'. בדוח, הוסיפו טבלה של כל הפיצ'רים שנבנו, תיאור הנוסחה, והמוטיבציה.

5. Error Analysis – ניתוח שגיאות

סעיף זה דורש ניתוח איכותי מעמיק, לא רק הרצת קוד.

5.1 חילוץ ה-outliers

מתוך התחזיות ב-cross validation, חלצו את 10 הסרטים עם ה-overprediction הגדול ביותר ואת 10 הסרטים עם ה-underprediction הגדול ביותר (סה"כ 20 סרטים) עבור המודל הטוב יותר.

5.2 ניתוח איכותי

ניתוח של 20 ה-outliers. נדרש שילוב של שני רבדים:

- עבור לפחות 5 סרטים ספציפיים – תיאור קצר (2–3 משפטים) של הסרט, השערה מדוע המודל טעה (מה המודל "לא יודע"?), והאם יש מאפיין ייחודי בסרט שגרם לשגיאה.
- זיהוי דפוסים משותפים בין ה-outliers: האם הם מז'אנר מסוים? תקציב מסוים? תקופה מסוימת? במאים ספציפיים? האם ה-overpredictions שונים בתכונותיהם מה-underpredictions?

5.3 השוואה בין המודלים

חלצו את 20 ה-outliers של שני המודלים. כמה מהם חופפים? כאשר מודל אחד טועה, האם השני מצליח יותר? אילו סוגי שגיאות ייחודיים לכל מודל?

5.4 הצעות לשיפור

על בסיס הניתוח – הציעו 2–3 פיצ'רים חדשים (שלא נבנו עד כה) שהערכתכם היא שהיו עוזרים לטפל בשגיאות המזוהות. נמקו.

6. Fairness Analysis – ניתוח הוגנות

עליכם לבחון האם המודל מדויק באותה מידה על חתכים שונים של הדאטה, או שיש קבוצות שהוא מבצע עליהן באופן לא פרופורציונלי.

6.1 חתכים נדרשים

יש לחשב RMSE ו-MAE על שניים מהחתכים הבאים:

- לפי ז'אנר – חמשת הז'אנרים הנפוצים ביותר בסט הנתונים (כל סרט יכול להופיע ביותר מז'אנר אחד)
- לפי מדינת מקור – US מול non-US (או חלוקה אחרת שתנמקו)
- לפי עשור יציאה – לפחות 3 עשורים
- לפי תקציב – שלישונים (נמוך / בינוני / גבוה), על סרטים עם budget לא חסר
- לפי זמניות שדות – סרטים עם budget+BoxOffice מול סרטים שחסר להם לפחות אחד מהם

6.2 הצגה חזותית

יש להציג את התוצאות גם בטבלה וגם בגרף השוואה (bar chart או דומה).

6.3 דיון

בדוח, יש להתייחס לשאלות הבאות:

- האם יש חתכים בהם המודל משמעותית פחות מדויק? בכמה (באחוזים ביחס לממוצע)?
- האם יש הסבר למה? (דוגמה: פחות דאטה, דאטה רועש, הבדלים באחידות המקור)
- האם זה מעלה חששות לגבי שימוש במודל בפועל? על אילו סרטים לא הייתם סומכים על החיזוי?
- האם חלוקות חסרי-נתונים (missingness) עשויות להיות מנבאות? האם הן משתלבות עם bias מסוים?

7. ניתוח חשיבות פיצ'רים

זהו את חמשת הפיצ'רים החשובים ביותר לכל מודל (Elastic Net): לפי מקדמים סטנדרטיים; מודל שני: לפי feature importance או permutation importance.

עבור כל פיצ'ר – ציינו את כיוון ההשפעה (חיובי/שלילי). השוו בין שני המודלים: האם הם מסכימים? איפה הם מתפצלים ולמה?

8. הערכה על Held-Out Test Set (תחרות)

במעמד הבדיקה, יופעלו הפונקציות שלכם על קובץ CSV של סרטים שאין בדאטה שלכם.

רצף ההפעלה: $df_2025 = pd.read_csv(...) \rightarrow X = prepare_data(df_2025) \rightarrow y_pred = model.predict(X)$. המטרה: RMSE מינימלי.

מנגנון הניקוד בסעיף התחרותי (10 נקודות בonus):

- המודל עם ה-RMSE הנמוך ביותר $\rightarrow 10$ נק'
- חמישייה ראשונה $\rightarrow 7$ נק'
- מחצית עליונה של הכיתה $\rightarrow 4$ נק'
- מודל שהוא baseline-beater (טוב מ-linear regression פשוט שנספק) $\rightarrow 2$ נק'
- מודל שנופל מתחת ל-baseline, או שהקוד לא רץ $\rightarrow 0$ נק'

9. דוח

דוח עד 8 עמודים (ללא נספחים), על פי החלוקה הבאה

- תיאור הדאטה המעובד וטבלת הפיצ'רים (כולל פיצ'רים הנדסיים)
- סעיף prepare_data ותיעוד השלבים
- השוואת שני המודלים, עם מדדי ביצועים מ-fold CV-10
- ניתוח חשיבות פיצ'רים
- Error analysis (סעיף 5) – פירוט מלא
- Fairness analysis (סעיף 6) – פירוט מלא
- מניעת data leakage – סעיף ייעודי
- מסקנות, מגבלות והצעות להמשך
- AI usage log: איפה התייעצתם עם LLM, על מה, ואיך אימתתם

10. דרישות הגשה

קובץ	תוכן נדרש
notebook.ipynb	קוד Python מלא כולל prepare_data, אימון, הערכה, error analysis ו-fairness analysis. הסברים inline ב-Markdown.
model.pkl	המודל המאומן הטוב יותר, serialized ב-pickle/joblib (ייתכן ב-test-time במעמד ההגנה)
report.pdf	דוח עד 8 עמודים – ראו סעיף 9
README.md	הוראות הרצה, רשימת דרישות (requirements.txt), תיאור קצר של המודל
requirements.txt	כל הספריות שבהן השתמשתם, עם גרסאות

דרישות טכניות

- Python 3.10 ומעלה
- הקוד חייב לרוץ end-to-end ללא שגיאות על dataset.csv
- שימוש ב-random_state=42 בכל מקום רלוונטי (reproducibility)
- repository ב-GitHub עם היסטוריית commits הגיונית (לא commit יחיד בסוף)

11. קריטריוני הערכה

ניקוד	קריטריון
20	איכות קוד, pipeline ו-prepare_data
15	Feature engineering
10	Error analysis
10	Fairness analysis
15	מניעת data leakage ומתודולוגיה תקינה (CV, Pipeline)
10	ניתוח חשיבות פיצ'רים והשוואת מודלים
10	דוח (בהירות, עומק, ויזואליזציה)
10	תחרות RMSE על held-out set
100	סה"כ

12. הגנה בעל-פה

לאחר ההגשה תתקיים הגנה קצרה (10–15 דקות) לחלק מהצוותים, שבה:

- נריץ את הקוד שלכם על test set ונמדוד RMSE
 - תידרשו להסביר החלטות מרכזיות: למה בחרתם את הפיצ'רים האלה, למה את המודל הזה, מה גיליתם ב-error analysis
 - נשאל שאלות על מניעת leakage ועל פרשנות התוצאות
- תשובה איכותית בעל-פה חשובה מאוד: אנו רוצים לראות שהצוות בנה את הפתרון והבין אותו, ולא רק ריצה של קוד גנרי.

13. יושרה אקדמית

יש לעבוד בנפרד / בצוות הרשום. שיתוף קוד בין צוותים אסור.

שימוש בכלי AI (ChatGPT, Claude וכו') **מותר** לצורך הסבר קוד, פתרון שגיאות, ודיוני עיצוב. **אסור** להגיש קוד שנוצר כולו על ידי AI ללא הבנה ואימות.

חובה: בנספח הדוח יש לכלול **AI usage log** – תיאור קצר של הנקודות שבהן התייעצתם עם LLM (על מה, למה, ואיך וידאתם שהקוד נכון). שקיפות תוערך לטובה; הסתרה שתגלה תיחשב כהפרת יושרה.

בהצלחה!