

דוח מטלת סיכום חלק 2 - חיזוי דירוג סרטים
מגישה: מיקה מלמד 207488453

1. תיאור הדאטה המעובד וטבלת הפיצ'רים

מטרת העבודה היא לבנות מודל Machine Learning לחיזוי דירוג ממוצע של סרטים, כלומר averageRating, על בסיס מידע שהיה יכול להיות ידוע לפני יציאת הסרט. הדאטה המקורי כלל 133,884 סרטים ו-13 עמודות: tconst, primaryTitle, startYear, genres, lead_actors_ids, runtimeMinutes, averageRating, Language, Country, numVotes, budget, BoxOffice, plot.

עמודת המטרה היא averageRating. מכיוון שמדובר בלמידה מפקחת, שורות שבהן averageRating חסר אינן יכולות לשמש לאימון המודל. לאחר סינון שורות ללא target נשארו 115,560 סרטים לאימון.

בשלב ניתוח הנתונים נמצאו ערכים חסרים רבים במספר עמודות: budget, BoxOffice, Country, Language, genres, plot. בנוסף, עמודות טקסטואליות כמו lead_actors_ids הופיעו בפורמטים לא אחידים: ערכים מופרדים בפסיקים, רשימות כטקסט, ערכי Not Found וערכים ריקים כמו [].

לאחר הפעלת prepare_data(df) התקבלה טבלת פיצ'רים מעובדת עם 30 פיצ'רים. הפיצ'רים כוללים משתנים נומריים, משתנים בינאריים ומשתנים קטגוריים. הטבלה הבאה מסכמת את הפיצ'רים המרכזיים שנבנו:

מוטיבציה	נוסחה / לוגיקה	Feature
שנת יציאה יכולה להשפיע על דירוגים, כי סרטים מתקופות שונות עשויים לקבל דפוס דירוג שונים.	המרת startYear לערך מספרי. ערך 0 מוגדר כחסר (NaN).	startYear
אורך הסרט עשוי להשפיע על חוויית הצפייה ועל הדירוג, למשל סרטים קצרים או ארוכים במיוחד.	המרת runtimeMinutes לערך מספרי.	runtimeMinutes
מייצג את גיל הסרט במקום שנת יציאה גולמית. זהו פיצ'ר נומרי מחושב שמאפשר למודל ללמוד הבדלים בין סרטים חדשים וישנים.	2026 - startYear	movie_age
שומר מידע על שנת יציאה לא תקינה במקום למחוק את השורה.	אם אין ערך בכלל או אם רשום 0, ייתן הערך 1. אחרת, ייתן הערך 0	has_missing_start_year
מייצג את רמת הרבז'אנריות של הסרט; סרטים עם כמה ז'אנרים עשויים לפנות לקהל רחב יותר או להיות מורכבים יותר מבחינת תוכן, ולכן ייתכן שיש לכך השפעה על הדירוג.	מספר הז'אנרים לאחר ניקוי עמודת genres.	num_genres
מייצג את הז'אנר המרכזי של הסרט, שיכול להיות קשור לדפוס הדירוג.	נלקח הז'אנר הראשון מתוך עמודת genres לאחר ניקוי הפורמט. אם אין ז'אנר תקין, הערך מוגדר כ-Unknown.	main_genre
מאפשרים למודל ללמוד השפעות של ז'אנרים ספציפיים.	אינדיקטורים בינאריים לז'אנרים נפוצים	is_drama, is_comedy, is_documentary, is_action, is_horror, is_sci_fi, is_animation, is_romance
מייצג את רוחב הפנייה הלשונית של הסרט ואת מידת הבינלאומיות שלו.	מספר השפות לאחר ניקוי Language	num_languages

has_language	1 אם קיים מידע שפה	הפיציר נועד לסמן האם קיים מידע על שפת הסרט. עצם הזמינות של שדה Language יכולה להעיד על איכות או שלמות הדאטה, ולעיתים סרטים עם מידע חסר רב עשויים להיות פחות מוכרים או פחות מתועדים, מה שיכול להשפיע על יכולת החיזוי של הדירוג.
is_english	1 אם מופיעה English	מציין אם הסרט כולל אנגלית. אנגלית עשויה להעיד על פנייה לשוק רחב יותר ועל חשיפה גבוהה יותר.
is_multilingual	אם $1 < \text{num_languages}$ או 1	מזהה סרטים רב-לשוניים. סרט רב-לשוני עשוי להעיד על הפקה בינלאומית או פנייה לקהלים מגוונים.
main_language	השפה הראשונה מתוך הרשימה לאחר ניקוי אם אין שפה תקינה אז Unknown	מייצג את השפה המרכזית של הסרט, שעשויה להשפיע על קהל היעד והדירוג.
has_country	1 אם קיים מידע מדינה	מסמן האם קיים מידע על מדינת ההפקה. חוסר מידע יכול להשפיע על איכות החיזוי.
num_countries	מספר המדינות לאחר ניקוי Country	מודד אם הסרט מקושר למדינה אחת או יותר.
is_us	אם המדינה כוללת United States, United, USA, States of America וכו' אז מסומן 1	מזהה סרטים הקשורים לארה"ב. סרטים אמריקאיים עשויים להיות שונים מבחינת הפקה, חשיפה ודפוסי דירוג.
is_international	אם $1 < \text{num_countries}$ או 1	מזהה סרטים עם יותר ממדינה אחת.
main_country	המדינה הראשונה מתוך הרשימה לאחר ניקוי אם אין מדינה תקינה אז Unknown	מייצג את מדינת ההפקה המרכזית, שעשויה להיות קשורה לסגנון, שוק יעד ודפוסי דירוג.
has_budget	1 אם נמצא ערך תקציב תקין לאחר ניקוי	משתמש בזמינות תקציב בלי להסתמך על ערך מספרי לא אחיד. זמינות תקציב יכולה להעיד על רמת תיעוד או על סרט מוכר/מסחרי יותר.
has_plot	1 אם קיים תקציר סרט	עצם קיום תקציר עשוי להעיד על סרט מתועד יותר, ולכן יכול לעזור בחיזוי.
plot_length	מספר התווים ב'plot'. אם אין תקציר, האורך הוא 0.	אורך התקציר עשוי להעיד על רמת פירוט וזמינות מידע על הסרט.
plot_word_count	מספר המילים ב'plot'. אם אין תקציר, מספר המילים הוא 0.	מדד נוסף לעושר המידע הטקסטואלי.
has_lead_actors	1 אם לאחר ניקוי קיימים שחקנים מובילים	מסמן האם יש מידע על הקאסט הראשי. חוסר מידע עשוי להעיד על סרט פחות מוכר או פחות מתועד.
num_lead_actors	מספר מזהי השחקנים ב'lead_actors_ids' לאחר ניקוי פורמטים	הפיציר נועד לייצג את כמות השחקנים הראשיים הידועים עבור הסרט. מספר גבוה יותר של שחקנים ראשיים יכול להעיד על קאסט רחב יותר, הפקה מתועדת יותר, או סרט בעל נוכחות גבוהה יותר.

יותר בדאטה. בנוסף, ערך 0 עשוי להעיד על מידע חסר, דבר שיכול להשפיע על איכות החיזוי.		
--	--	--

הפיצ'ר `movie_age` משמש כפיצ'ר נומרי מחושב מתוך `startYear`. הוא לא עותק ישיר של עמודה גולמית, אלא טרנספורמציה בעלת משמעות: במקום שנת יציאה, המודל מקבל את גיל הסרט.

2. סעיף `prepare_data(df)` ותיעוד השלבים

הפונקציה `prepare_data(df)` נבנתה כך שתהיה עצמאית ודטרמיניסטית. כלומר, היא מקבלת `DataFrame` גולמי ומחזירה טבלת פיצ'רים מוכנה למודל. הפונקציה לא מניחה שהדאטה כבר נוקה מראש, והיא יכולה לעבוד גם על `df_train`, גם על `X_raw` וגם על שורה בודדת.

הפונקציה מבצעת את הפעולות הבאות:

1. המרה של `startYear` ו-`runtimeMinutes` לערכים נומריים.
2. טיפול ב-`startYear = 0` כערך חסר, ויצירת `has_missing_start_year`.
3. יצירת `movie_age`.
4. ניקוי עמודות מרובות ערכים באמצעות `parse_multi_value_cell`, כולל `genres`, `Language`, `Country` ו-`lead_actors_ids`.
5. יצירת פיצ'רים מז'אנרים, שפות, מדינות, תקציב, תקציר ושחקנים.
6. החזרת פיצ'רים סופיים בלבד, ללא עמודות גולמיות וללא עמודות `leakage`.

הפונקציה לא מבצעת פעולות סטטיסטיות כגון:

- השלמת ערכים חסרים לפי `mean` או `median`.
- `StandardScaler`.
- `OneHotEncoder`.

פעולות אלה הוכנסו לתוך `Pipeline`, כדי שילמדו רק על `fold` האימון בכל שלב של `cross-validation`.

הפונקציה נבדקה בשלושה מצבים:

- הפעלה על `X_raw`.
- הפעלה על `df_train` המלא, שכולל גם את עמודות ה-`target` וה-`leakage`.
- הפעלה על שורה בודדת.

בכל המקרים התקבל אותו מבנה פיצ'רים של 30 עמודות. בנוסף, בדיקת התאמה בין `prepare_data(X_raw)` לבין `prepare_data(df_train)` החזירה `(True, True)`, כלומר הפלטים זהים. הדבר מאשר שהפונקציה עצמאית ומתעלמת מעמודות שאינן צריכות להיכנס למודל.

3. מניעת `data leakage`

הוקדש סעיף נפרד למניעת `data leakage`, מאחר שזהו חלק מהותי במטלה.

העמודות שהוסרו מהקלט למודל הן:

- `averageRating` - זהו משתנה המטרה עצמו.
- `numVotes` - מספר הצבעות ידוע רק לאחר שהסרט יצא וקיבל דירוגים.
- `BoxOffice` - הכנסות הסרט ידועות רק לאחר יציאת הסרט.

שימוש באחת מהעמודות האלה כ־feature היה גורם למודל לקבל מידע שאינו זמין בזמן אמת לפני יציאת הסרט, ולכן היה יוצר תחזיות לא הוגנות ולא ריאליסטיות.

בנוסף, סינון שורות ללא averageRating נעשה מחוץ ל־prepare_data, משום שסינון זה קשור להכנת נתוני אימון בלבד. הפונקציה prepare_data(df) צריכה לעבוד גם על test חיצוני, שבו ייתכן שאין כלל עמודת target.

גם בעמודות budget ננקטה זהירות. למרות שתקציב עשוי להיות מידע זמין לפני יציאת הסרט, הערכים בעמודה היו לא אחידים: חלק הופיעו כערכים קטנים כמו 5.0, 20.0, וחלק כטקסט כגון \$5 million או ₹25 crore. לכן לא נעשה שימוש ב־budget_clean או log_budget כמשתנים נומריים במודל הבסיסי. במקום זאת השתמשנו רק ב־has_budget, שמייצג האם נמצא מידע תקציבי תקין.

4. השוואת שני המודלים עם מדדי ביצועים מ־10-fold CV

נבנו שני מודלים:

1. Elastic Net
2. DecisionTreeRegressor

המודל הראשון - Elastic Net, נדרש במטלה. עבורו בוצע tuning של:

- alpha
- l1_ratio

באמצעות GridSearchCV עם 10-fold cross-validation. ערכי הפרמטרים הטובים ביותר שנמצאו היו:

- alpha = 0.001
- l1_ratio = 0.1

המודל השני שנבחר הוא DecisionTreeRegressor. הבחירה בו נעשתה משום שהוא מספק השוואה ברורה ל־Elastic Net: בעוד Elastic Net הוא מודל ליניארי רגולרי, Decision Tree מסוגל לתפוס יחסים לא ליניאריים ואינטראקציות בין פיצ'רים. בנוסף, הוא יחסית פרשני ומהיר יותר להערכה לעומת Random Forest בדאטה גדול ובעל פיצ'רים רבים לאחר OneHotEncoder. Random Forest נשקל כמודל שני, אך הערכה שלו באמצעות 10-fold cross-validation הייתה יקרה מדי מבחינת זמן ריצה. לכן נבחר Decision Tree כמודל פרקטי, פרשני ולא ליניארי.

תוצאות 10-fold CV:

Model	RMSE	MAE	R ²
Elastic Net	1.1177	0.8543	0.2490
Decision Tree	1.1177	0.8547	0.2488

ההבדלים בין המודלים קטנים מאוד, אך Elastic Net השיג תוצאות מעט טובות יותר במדדי RMSE, MAE, ו־R². לכן הוא נבחר כמודל הסופי.

שני המודלים הגיעו לתוצאות דומות מאוד, ככל הנראה משום שהם למדו דפוסים דומים מתוך אותם פיצ'רים. מאחר שהחיוזי נעשה לפני יציאת הסרט לאקרנים, לא נעשה שימוש במשתנים חזקים אך אסורים כמו averageRating, numVotes, BoxOffice, כדי למנוע Data Leakage. כתוצאה מכך, המידע הזמין למודלים היה מוגבל יחסית והתבסס בעיקר על מאפיינים כלליים כמו ז'אנר, שנת יציאה, משך הסרט, שפה, מדינה. בנוסף, עץ ההחלטה הוגבל באמצעות פרמטרים כגון עומק מקסימלי ומספר מינימלי של דגימות בעלה, ולכן הוא לא ביצע התאמת יתר ולא התרחק משמעותית מהביצועים של מודל Elastic Net. מסיבה זו, סביר ששני המודלים הגיעו לרמת ביצועים דומה מאוד על סט הנתונים.

5. ניתוח חשיבות פיז'רים

ב-Elastic Net, חשיבות פיז'רים נותחה לפי ערך מוחלט של המקדמים הסטנדרטיים. מקדם חיובי מעלה את תחזית הדירוג, ומקדם שלילי מוריד אותה.

חמשת הפיז'רים החשובים ביותר ב-Elastic Net היו:

1. main_genre_Music - השפעה חיובית.
2. main_language_Hindi - השפעה שלילית.
3. main_language_Marathi - השפעה חיובית.
4. main_genre_Sci-Fi - השפעה שלילית.
5. is_documentary - השפעה חיובית.

המקדם החיובי של is_documentary אומר שהמודל בדרך כלל מקשר סרטים דוקומנטריים עם דירוגים גבוהים יותר. זה אינו סותר את Error Analysis, אלא דווקא מסביר אותו: המודל למד שדוקומנטריים נוטים לקבל דירוגים גבוהים יותר בממוצע, ולכן כאשר מגיע דוקומנטרי עם דירוג אמיתי נמוך במיוחד, המודל עדיין חוזה לו דירוג גבוה יחסית. כתוצאה מכך נוצרים overpredictions גדולים בדוקומנטריים חלשים.

ב-Decision Tree, חשיבות פיז'רים נותחה לפי feature_importances_. מאחר שלעץ החלטה אין מקדמים חיוביים/שליליים, כיוון ההשפעה הוערך לפי הקשר בין ערכי הפיז'ר לבין תחזיות המודל.

חמשת הפיז'רים החשובים ביותר ב-Decision Tree היו:

1. is_documentary - כיוון משוער חיובי.
2. is_horror - כיוון משוער שלילי.
3. runtimeMinutes - כיוון משוער חיובי.
4. is_drama - כיוון משוער חיובי.
5. startYear - כיוון משוער שלילי.

שני המודלים מסכימים שז'אנר הוא מידע חשוב, ובפרט ש-is_documentary משמעותי. עם זאת Elastic Net, נותן חשיבות גבוהה לקטגוריות ספציפיות לאחר OneHotEncoder, כמו main_genre_Music, main_language_Hindi, בעוד Decision Tree נשען יותר על אינדיקטורים רחבים כמו is_documentary, is_horror, ועל פיז'רים נומריים כמו runtimeMinutes ו-startYear.

6. Error Analysis

בוצע Error Analysis על מודל Elastic Net, שנבחר כמודל הטוב יותר. לשם כך הופקו תחזיות out-of-fold באמצעות cross_val_predict, כך שכל סרט נחזה על ידי מודל שלא אומן עליו.

חושבו:

$$\text{prediction_error} = \text{predicted_rating} - \text{actual_rating}$$

absolute_error

נשלפו:

- 10% overpredictions הגדולים ביותר.
- 10% underpredictions הגדולים ביותר.

ב-overpredictions, הדירוגים האמיתיים היו נמוכים מאוד, לרוב בין 1.0 ל-1.7, אך המודל חזה להם דירוגים סביב 6.9–8.0. רוב המקרים היו דוקומנטריים.

ב-underpredictions, הדירוגים האמיתיים היו גבוהים מאוד, לרוב בין 8.9 ל-10.0, אך המודל חזה להם דירוגים סביב 4.4–5.6. רבים מהמקרים היו סרטי Action, Horror, או סרטי ז'אנר אחרים עם metadata מוגבל.

נותחו שישה סרטים ספציפיים :

- At the Back of the Screen
- Horseplay: The History of Horse Riding
- Justin Bieber: Always Believing
- Bukunja Tekunja Mitti: The Cannibals
- Akkada Varu Ikkada Unnaru
- Hell Squad 2: Fresh Meat

עבור כל סרט נכתב תיאור קצר, סוג השגיאה, ומה המודל כנראה לא ידע. המסקנה המרכזית היא שהמודל מתקשה במיוחד עם דירוגים קיצוניים. הוא נוטה למשוך תחזיות לאזור האמצע, ולכן מפספס סרטים שקיבלו דירוגים נמוכים מאוד או גבוהים מאוד.

בנוסף, הושוו השגיאות הגדולות בין Elastic Net לבין Decision Tree. נמצאו 11 סרטים חופפים מתוך 20 ה־outliers של כל מודל. כלומר, יותר ממחצית מהשגיאות הגדולות משותפות לשני המודלים. הדבר מעיד שהבעיה אינה רק בבחירת המודל, אלא גם במגבלות הפיצ'רים הקיימים.

בדפוסים המשותפים נמצא :

- 8 מתוך 10 ה־overpredictions של Elastic Net היו דוקומנטריים.
- ה־underpredictions היו מגוונים יותר, בעיקר Action ו־Horror.
- בקבוצת ה־underprediction, בממוצע לא היה מידע על שפה, מדינה, תקציב או תקציר.
- שתי הקבוצות סבלו ממחסור ב־metadata, אך המחסור היה חזק יותר בקבוצת ה־underprediction.

Fairness Analysis.7

ב־Fairness Analysis נבדק האם המודל מדויק באותה מידה על קבוצות שונות של סרטים. השתמשנו במודל Elastic Net ובתחזיות out-of-fold.

נבדקו שני חתכים :

1. לפי main_genre
2. לפי US מול Non-US / Unknown

ביצועים לפי ז'אנר

חמשת הז'אנרים הנפוצים ביותר נבדקו לפי MAE ו־RMSE :

Genre	n_movies	MAE	RMSE
Action	13,987	0.961	1.223
Comedy	27,975	0.855	1.116
Drama	33,564	0.813	1.068
Documentary	10,496	0.770	1.048
Crime	6,390	0.762	1.001

המודל פחות מדויק על סרטי Action. ה־RMSE של Action הוא 1.223, לעומת ה־RMSE הכללי של Elastic Net, שהוא 1.118. כלומר, השגיאה ב־Action גבוהה בכ־9.4% ביחס לממוצע הכללי.

לעומת זאת Crime, קיבל RMSE של 1.001, כלומר נמוך בכ־10.4% מהממוצע הכללי. לכן יש הבדל ברור בביצועי המודל בין ז'אנרים.

אין כאן סתירה מול ה־Error Analysis: שם הסתכלנו רק על 20 השגיאות הקיצוניות, ולכן דוקומנטריים בלטו מאוד. כאן אנחנו מסתכלים על ממוצע כל הסרטים בכל ז'אנר, ובממוצע סרטי Action קשים יותר למודל.

ביצועים לפי US מול Non-US / Unknown

Genre	n_movies	MAE	RMSE
US	21,178	0.728	0.960
Non-US / Unknown	94,382	0.883	1.152

המודל מדויק יותר על סרטי US. עבור סרטי US, ה' RMSE הוא 0.960, כלומר נמוך בכ-14.1% מה' RMSE הכללי. עבור Non-US / Unknown, ה' RMSE הוא 1.152, כלומר גבוה בכ-3.0% מה' RMSE הכללי.

כלומר, יש פער ביצועים בין קבוצות. ייתכן שסרטי US מיוצגים טוב יותר בדאטה או שה' metadata שלהם אחיד ושלם יותר. לעומת זאת, קבוצת Non-US / Unknown כוללת הרבה סרטים עם מדינה חסרה, שפה חסרה, תקציר חסר או מידע פחות אחיד.

האם יש bias ומה תפקיד ה' missingness?

יש עדות לפערי ביצועים בין קבוצות, כלומר המודל לא מדויק באותה מידה בכל החתכים. נראה ש' missingness קשור לשגיאה. בקבוצת ה' underpredictions, כמעט לא היה מידע על שפה, מדינה, תקציב או תקציר. זה מציע שהיעדר מידע יכול לגרום למודל לחזות קרוב יותר לממוצע, ולהחמיץ סרטים עם דירוגים חריגים מאוד.

לכן לא הייתי סומכת על החיזוי באותה מידה עבור:

- סרטים עם main_country = Unknown
- סרטים עם main_language = Unknown
- סרטים ללא plot
- סרטים ללא תקציב
- סרטי Action או Horror עם metadata מוגבל
- דוקומנטריים חריגים

הדבר תומך בהצעה להוסיף בעתיד, metadata_completeness_score, שיכול למדוד כמה מידע זמין לכל סרט.

8. הצעות לשיפור על בסיס Error Analysis

בהתבסס על ניתוח השגיאות, הוצעו שלושה פיצורים עתידיים:

1. Actor Pre-Release Popularity

במקרים רבים של underprediction, לסרטים היו שחקנים מובילים, אך המודל ידע רק את מספר השחקנים ולא אם הם פופולריים או מצליחים. לכן אפשר ליצור פיצור שמחשב, רק לפי סרטים קודמים, כמה סרטים השחקנים עשו או מה ממוצע הדירוג של סרטיהם הקודמים. יש להיזהר מ' data leakage, ולכן הפיצור צריך להיבנות רק על סרטים שיצאו לפני הסרט הנוכחי.

2. Director or Creator Information

הדאטה הנוכחי לא כולל מידע על במאים או יוצרים. מוניטין של במאי יכול להיות משמעותי מאוד באיכות הסרט ובציפיות הקהל. פיצור כזה יכול לעזור גם בזיהוי סרטי Action או Horror עם פוטנציאל גבוה וגם בהבחנה בין דוקומנטריים טובים לדוקומנטריים שקיבלו דירוג נמוך מאוד.

3. Metadata Completeness Score

ניתוח השגיאות הראה שחוסר מידע מופיע הרבה במקרים שבהם המודל טועה. לכן אפשר ליצור פיצור שמודד כמה מידע זמין לכל סרט: האם קיימת שפה, מדינה, תקציב, תקציר ושחקנים. פיצור כזה יכול ללמד את המודל שסרטים עם metadata מוגבל דורשים תחזית זהירה יותר.

9. מסקנות, מגבלות והמשך

המודל הסופי שנבחר הוא Elastic Net, מכיוון שהוא השיג ביצועים מעט טובים יותר מ-Decision Tree. הביצועים היו:

- $RMSE \approx 1.118$
- $MAE \approx 0.854$
- $R^2 \approx 0.249$

המודל מצליח ללמוד חלק מהדפוסים בדאטה, בעיקר סביב ז'אנרים, שנת יציאה, אורך סרט וזמינות metadata. עם זאת, ערך R^2 של כ-0.25 מצביע על כך שחלק גדול מהשונות בדירוגים עדיין לא מוסבר. המגבלות המרכזיות הן:

- קיימים הרבה ערכים חסרים בעמודות חשובות כמו 'Language', 'Country', 'budget' ו-'plot'.
- קיימים פורמטים לא אחידים בעמודות טקסטואליות, למשל רשימות כטקסט, ערכים מופרדים בפסיקים, 'Not Found', וערכים ריקים.
- חוסר מידע על במאים, פופולריות שחקנים, ביקורות, שיווק, קהל יעד.
- קושי בחיזוי דירוגים קיצוניים.
- ביצועים פחות טובים על קבוצות מסוימות, בעיקר Non-US / Unknown ו-Action.
- למרות ש-'averageRating' הוא משתנה המטרה, המודל אינו משתמש ב-'numVotes' כדי להימנע מ-'data leakage'. לכן הוא לא יודע האם הדירוג מבוסס על הרבה מדרגים או על מעט מדרגים, מה שעלול להשפיע על יציבות הדירוג.
- בגלל אי-אחידות גבוהה בעמודת 'budget', לא השתמשנו בערך התקציב המספרי עצמו אלא רק ב-'has_budget'. לכן המודל לא מנצל מידע כמותי על גודל ההפקה.

לשימוש בפועל, יש להיזהר במיוחד בתחזיות עבור סרטים עם metadata חסר, סרטים שאינם מזוהים כ-US, וסרטים מז'אנרים שבהם המודל פחות מדויק. שיפורים עתידיים צריכים להתמקד בהעשרת metadata, הוספת מידע על שחקנים ובמאים, והוספת פיצ'רים שמייצגים את רמת שלמות המידע.

10. AI usage log

נעזרתי ב-LLM בשלושה היבטים מרכזיים:

1. **Feature Engineering** - לצורך חשיבה על פיצ'רים אפשריים שניתן להפיק מתוך העמודות הקיימות, כגון genres, Language, Country, plot, budget ו-lead_actors_ids. לאחר מכן בחנתי את הרעיונות מול הדאטה בפועל ובחרתי רק פיצ'רים שמתאימים למידע שיכול להיות זמין לפני יציאת הסרט.
2. **ניסוח והצגת ההסברים** - לצורך שיפור ניסוחים בדוח ובמחברת, כך שההחלטות שבוצעו בתהליך הניקוי, בניית prepare_data(df), מניעת data leakage, השוואת המודלים וניתוחי Error Analysis ו-Fairness Analysis יוצגו בצורה ברורה ומסודרת.
3. **בדיקת פרשנות התוצאות** - לצורך וידוא שהפרשנות של מדדי הביצוע, חשיבות הפיצ'רים, השגיאות והחתכים השונים תואמת את הפלטים שהתקבלו במחברת.